

# **Ajuste de Curvas: Método dos Mínimos Quadrados**

Prof. Dr. Rogério Galante Negri


---

# Motivação



- Suponhamos que foi medido em laboratório o crescimento médio de pés de feijão:

| Dia         | 3   | 10  | 13  | 17  | 22 |
|-------------|-----|-----|-----|-----|----|
| Altura (cm) | 2.2 | 7.7 | 9.2 | 9.9 | 11 |



- Como fazemos para conhecer o valor no 6º dia?
- Em que dia (decimal) os feijões atingem altura de 10 cm?

Questões como esta são resolvidas com auxílio da Interpolação:  
“Aproximação da função original por uma outra, escolhida dentre uma classe de funções que satisfaz determinadas propriedades”

# Contraindicações da Interpolação

- A interpolação é usada para aproximar uma função da qual só conhecemos poucos pontos
  - Ela não é indicada para:
    - Determinar valores da função fora do intervalo “interpolado” (não há extrapolação)
    - Os dados tabelados são obtidos de experimentos, pois, os mesmos contém erros inerentes não previsíveis
  - Tais contraindicações motiva ajuste de funções aos valores tabelados, da melhor forma possível
  - Dessa forma, é possível extrapolar informações com segurança
-

# Casos de Ajuste

- Dois casos para ajuste de curvas são:
    - Discreto
    - Contínuo
  - Discreto: ajuste de curvas sobre um conjunto de pontos  $(x_i, f(x_i))$ ,  $i = 1, \dots, n$  tabelados
  - Contínuo: ajuste de curvas sobre uma função  $f(x)$  contínua definida em um intervalo  $[a, b]$
-

# Caso discreto


- O ajuste é feito sobre os pontos  $(x_1, f(x_1)), \dots, (x_m, f(x_m))$  com  $x_1, \dots, x_m \in [a, b]$
- Para realizar o ajuste:
  - Escolher  $n$  funções  $g_1(x), \dots, g_n(x)$  contínuas em  $[a, b]$
  - Obter  $n$  constantes  $\alpha_1, \dots, \alpha_n$  de forma que:

$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$


seja a mais próxima possível de  $f(x)$

- Observa-se que:
    - É um modelo linear, já que as constantes  $\alpha_i$  aparecem linearmente
    - As funções  $g_i(x)$  podem não ser lineares
    - A escolha das  $g_i(x)$ 's é feita pela observação do diagrama de dispersão dos pontos tabelados
-

# Diagrama de dispersão




- Suponhamos os diagramas (obtidos experimentalmente)
- Podemos observar um comportamento bem estabelecido
- Nem sempre é possível...



# Menor desvio

- Nos exemplos anteriores, qual reta, parábola e exponencial são as que melhor se ajustam?
- Com a escolha das funções  $g_i(x)$ 's, é observada a proximidade entre  $\varphi(x)$  e  $f(x)$
- Uma maneira é exigir o menor desvio  $f(x) - \varphi(x)$
- O Método dos Mínimos Quadrados (MMQ) determina tal  $\varphi(x)$



# Caso contínuo

- Dada  $f(x)$  contínua em  $[a, b]$  e escolhidas  $g_1(x), \dots, g_n(x)$ , também contínuas em  $[a, b]$
  - Podemos definir  $\varphi(x) = \alpha_1 g_1(x) + \dots + \alpha_n g_n(x)$  que se aproxime o máximo possível de  $f(x)$
  - A proximidade pode ser dada pela área sob o gráfico de  $\varphi(x) - f(x)$
  - Área mínima equivale a maior proximidade
-



# MMQ – Caso Discreto

- Dados  $(x_i, f(x_i))$ ,  $i = 1, \dots, m$ , e  $g_j(x)$ ,  $j = 1, \dots, n \leq m$
- Devemos determinar os coef.  $\alpha_j$ ,  $j = 1, \dots, n$  tal que:  
$$\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x) + \dots + \alpha_n g_n(x)$$
seja a mais próxima possível de  $f(x)$
- Desejamos  $d_k = f(x_k) - \varphi(x_k)$  mínimo,  $k = 1, \dots, m$
- O MMQ consiste em selecionar os  $\alpha_i$ 's que minimiza a seguinte função (soma dos quadrados dos desvios) :

$$F(\alpha_1, \alpha_2, \dots, \alpha_n) = \sum_{k=1}^m d_k^2 = \sum_{k=1}^m (f(x_k) - \varphi(x_k))^2$$

# MMQ – Caso Discreto

- O mínimo de  $F(\alpha_1, \alpha_2, \dots, \alpha_n)$  está vinculado aos pontos críticos, isto é:

$$\left. \frac{\partial F}{\partial \alpha_j} \right|_{(\alpha_1, \alpha_2, \dots, \alpha_n)} = 0; j = 1, \dots, n$$

- Sabemos que:

$$\left. \frac{\partial F}{\partial \alpha_j} \right|_{(\alpha_1, \dots, \alpha_n)} = 2 \sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \dots - \alpha_n g_n(x_k)) \cdot (-g_j(x_k))$$

Verifique

- Exigindo  $\left. \frac{\partial F}{\partial \alpha_j} \right|_{(\alpha_1, \alpha_2, \dots, \alpha_n)} = 0; j = 1, \dots, n$ , temos:

$$\sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \dots - \alpha_n g_n(x_k)) \cdot (-g_j(x_k)) = 0$$

para  $j = 1, \dots, n$

# MMQ – Caso Discreto

- Uma vez que

$$\sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \cdots - \alpha_n g_n(x_k)) \cdot (-g_j(x_k)) = 0$$

para  $j = 1, \dots, n$ , podemos escrever:

$$\left\{ \begin{array}{l} \sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \cdots - \alpha_n g_n(x_k)) \cdot (-g_1(x_k)) = 0 \\ \sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \cdots - \alpha_n g_n(x_k)) \cdot (-g_2(x_k)) = 0 \\ \vdots \\ \sum_{k=1}^m (f(x_k) - \alpha_1 g_1(x_k) - \cdots - \alpha_n g_n(x_k)) \cdot (-g_n(x_k)) = 0 \end{array} \right.$$

continua...

# MMQ – Caso Discreto

$$\begin{cases} \left( \sum_{k=1}^m g_1(x_k) \cdot g_1(x_k) \right) \alpha_1 + \cdots + \left( \sum_{k=1}^m g_n(x_k) \cdot g_1(x_k) \right) \alpha_n = \sum_{k=1}^m f(x_k) \cdot g_1(x_k) \\ \left( \sum_{k=1}^m g_1(x_k) \cdot g_2(x_k) \right) \alpha_1 + \cdots + \left( \sum_{k=1}^m g_n(x_k) \cdot g_2(x_k) \right) \alpha_n = \sum_{k=1}^m f(x_k) \cdot g_2(x_k) \\ \vdots \\ \left( \sum_{k=1}^m g_1(x_k) \cdot g_n(x_k) \right) \alpha_1 + \cdots + \left( \sum_{k=1}^m g_n(x_k) \cdot g_n(x_k) \right) \alpha_n = \sum_{k=1}^m f(x_k) \cdot g_n(x_k) \end{cases}$$

$$\begin{cases} a_{11}\alpha_1 + a_{12}\alpha_2 + \cdots + a_{1n}\alpha_n = b_1 \\ a_{21}\alpha_1 + a_{22}\alpha_2 + \cdots + a_{2n}\alpha_n = b_2 \\ \vdots \\ a_{n1}\alpha_1 + a_{n2}\alpha_2 + \cdots + a_{nn}\alpha_n = b_n \end{cases}$$

$$\text{SL: } \mathbf{A} \cdot \boldsymbol{\alpha} = \mathbf{b}$$

onde  $a_{ij} = \underbrace{\sum_{k=1}^m g_i(x_k) \cdot g_j(x_k)}_{\langle \mathbf{g}_i, \mathbf{g}_j \rangle}$  e  $b_i = \underbrace{\sum_{k=1}^m f(x_k) \cdot g_i(x_k)}_{\langle \mathbf{f}, \mathbf{g}_i \rangle}$

# MMQ – Caso Discreto

- Dado  $\mathbf{g}_i = (g_i(x_1), g_i(x_2), \dots, g_i(x_m))^T$
- Se  $\mathbf{g}_1, \dots, \mathbf{g}_n$  são Linearmente Independentes então  $\det(\mathbf{A}) \neq 0$
- Logo, o SL possui solução única  $\bar{\alpha} = (\bar{\alpha}_1, \dots, \bar{\alpha}_n)$
- Ainda,  $\bar{\alpha}$  é o ponto de mínimo de  $F(\alpha_1, \alpha_2, \dots, \alpha_n)$

- 
- Se os vetores  $\mathbf{g}_i$  são tais que o produto escalar

$$\langle \mathbf{g}_i, \mathbf{g}_j \rangle: \begin{cases} = 0, & \text{se } i \neq j \\ \neq 0, & \text{se } i = j \end{cases}$$

ou seja, ortogonais, teremos  $\mathbf{A}$  diagonal, com  $a_{ii} \neq 0$  e com solução fácil de calcular [pense!]

O melhor de tudo é que, a partir de  $x_1, \dots, x_m$ , é simples obter polinômios de grau 0 até  $n$  que sejam ortogonais

# Exercício – Caso Discreto

- Aproxime uma função para o seguinte conjunto de pontos:

| $x$    | -2    | -1   | 0    | 1    | 2     | 3    |
|--------|-------|------|------|------|-------|------|
| $f(x)$ | 19.01 | 3.99 | -1.0 | 4.01 | 18.99 | 45.0 |

# MMQ – Caso Contínuo

**Por simplicidade,  
adotaremos apenas  
duas funções**

- Desejamos que  $\varphi(x) = \alpha_1 g_1(x) + \alpha_2 g_2(x)$  se aproxime o máximo possível de  $f(x)$  em  $[a, b]$
- Precisamos obter  $\alpha_1$  e  $\alpha_2$  tais que  $\int_a^b (f(x) - \varphi(x))^2 dx$  seja o menor possível
- Desenvolvendo:

$$\begin{aligned} F(\alpha_1, \alpha_2) &= \int_a^b (f(x) - \varphi(x))^2 dx = \\ &= \int_a^b f(x)^2 dx - 2\alpha_1 \int_a^b f(x)g_1(x)dx - 2\alpha_2 \int_a^b f(x)g_2(x)dx + \\ &\quad + \alpha_1^2 \int_a^b g_1^2(x)dx + 2\alpha_1\alpha_2 \int_a^b g_1(x)g_2(x)dx + \alpha_2^2 \int_a^b g_2^2(x)dx \end{aligned}$$

# MMQ – Caso Contínuo

- Determinamos os pontos críticos de  $F(\alpha_1, \alpha_2)$  fazendo:

$$\left. \frac{\partial F}{\partial \alpha_j} \right|_{(\alpha_1, \alpha_2)} = 0; \quad j = 1, 2$$

- Para  $\alpha_1$ :

$$\left. \frac{\partial F}{\partial \alpha_1} \right|_{(\alpha_1, \alpha_2)} = -2 \int_a^b f(x) g_1(x) dx + 2\alpha_1 \int_a^b g_1^2(x) dx + 2\alpha_2 \int_a^b g_1(x) g_2(x) dx$$

- Para  $\alpha_2$ :

$$\left. \frac{\partial F}{\partial \alpha_2} \right|_{(\alpha_1, \alpha_2)} = -2 \int_a^b f(x) g_2(x) dx + 2\alpha_2 \int_a^b g_2^2(x) dx + 2\alpha_1 \int_a^b g_1(x) g_2(x) dx$$

**$A \cdot \alpha = b$**

$$\begin{cases} \overbrace{\alpha_1 \int_a^b g_1^2(x) dx}^{a_{11}} + \overbrace{\alpha_2 \int_a^b g_1(x) g_2(x) dx}^{a_{12}} = \overbrace{\int_a^b f(x) g_1(x) dx}^{b_1} \\ \underbrace{\alpha_1 \int_a^b g_1(x) g_2(x) dx}_{a_{21}} + \underbrace{\alpha_2 \int_a^b g_2^2(x) dx}_{a_{22}} = \underbrace{\int_a^b f(x) g_2(x) dx}_{b_2} \end{cases}$$



# MMQ – Caso Contínuo

- Assim como no caso discreto, se  $g_1$  e  $g_2$  são LI, temos  $\det(\mathbf{A}) \neq 0$ , logo, o SL tem solução única  $\bar{\alpha} = (\bar{\alpha}_1, \dots, \bar{\alpha}_n)$
  - A solução  $\bar{\alpha}$  é ponto de mínimo de  $F(\alpha_1, \alpha_2)$
- 

- Considerando o produto escalar entre funções  $p(x)$  e  $q(x)$ :

$$\langle p(x), q(x) \rangle = \int_a^b p(x)q(x)dx \quad \star$$

- Temos por sua vez que:

$$(a_{ij}) = \langle g_i(x), g_j(x) \rangle = \int_a^b g_i(x)g_j(x)dx$$
$$b_i = \langle f(x), g_i(x) \rangle = \int_a^b f(x)g_i(x)dx$$

É possível obter funções ortogonais para o produto interno ★

# Polinômios de Legendre

$$\mathcal{L}_0(x) = 1$$
$$\mathcal{L}_k(x) = \frac{1}{2^k k!} \cdot \frac{d^{(k)}}{dx^{(k)}} (x^2 - 1)^k; \quad k = 1, 2, \dots$$

são ortogonais em  $[-1, +1]$  segundo ★

- Existe ainda uma relação de recorrência para obtenção dos polinômios de Legendre:

$$\mathcal{L}_{k+1}(x) = \left( \frac{2j+1}{j+1} \right) x \mathcal{L}_k(x) - \left( \frac{j}{j+1} \right) \mathcal{L}_{k-1}(x); \quad k = 1, 2, \dots$$

# Exercício – Caso Contínuo

- Aproxime a função  $f(x) = e^{-x}$  em  $[1,3]$  por um polinômio de grau 1 na forma  $g(x) = \alpha_1 x + \alpha_2$
-

# Tratamento Não Linear

- Há casos em que as funções escolhidas para ajuste não sejam lineares nos parâmetros  $\alpha$ , por exemplo:

$$\varphi(x) = \alpha_1 e^{-\alpha_2 x}$$

- Para uso do MMQ, deve-se linearizar o problema:

$$\varphi(x) = \alpha_1 e^{-\alpha_2 x} \Rightarrow \phi(x) = \ln(\varphi(x)) = \ln(\alpha_1) - \alpha_2 x$$

- Definindo,  $\hat{\alpha}_1 = \ln(\alpha_1)$  e  $\hat{\alpha}_2 = -\alpha_2$  temos  $\phi(x)$  linear nos parâmetros  $\hat{\alpha}_1$  e  $\hat{\alpha}_2$
- Após essas considerações, o MMQ é aplicado ao problema linearizado

Os parâmetros obtidos são usados para determinar os parâmetros originais




# Exemplo

- Considerando os seguintes dados abaixo, faça uma ajuste não-linear. Considere  $\varphi(x) = \alpha_1 e^{-\alpha_2 x}$

| $x$    | -1.0   | -0.7   | -0.4  | -0.1  | 0.2  | 0.5  | 0.8   | 1.0   |
|--------|--------|--------|-------|-------|------|------|-------|-------|
| $f(x)$ | 36.547 | 17.264 | 8.155 | 3.852 | 1.82 | 0.86 | 0.406 | 0.246 |

# Verificando o Ajuste Não Linear

- i. Obter a versão linearizada da função original
- ii. Aplicar sobre os dados tabelados
- iii. Fazer o diagrama de dispersão
- iv. Se os pontos no diagrama estiverem alinhados, então a função usada na linearização foi uma boa escolha



# Bibliografia da aula

- RUGGIERO, M. A. G.; LOPES, V. L. R. **Cálculo Numérico - Aspectos Teóricos e Computacionais**, 2ª Ed. Editora Pearson, 1996.
- FRANCO, N. B. **Cálculo Numérico**. Pearson, 2007.

